嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：Olist 电商客户分群与销售结构可视化分析

学　　院：数据科学学院

专业班级：大数据 242

学　　号：2024459985223

姓　　名：陈俊源

完成日期：2026 年 10 月 29 日

评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20分）	① 模型≥3种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25分）	① 图表≥10张、类别覆盖全面（6）；② 模板复现≥10种、风格细节贴近原作（7）；③ 业务模型图≥6张、与模型对应（6）；④ 交互大屏≥1个、组件≥6、有联动/下钻（6）	
4. 代码规范性与文档完整性（10分）	① 目录结构清晰、注释充分（3）；②README 详实、依赖明确（3）；③可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25分）	① 题目创新性与针对性（4）；② 摘要概括性、关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5分）	① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1）	
总 分	（各维度得分相加）	

数 据 科 学 学 院

Olist 电商客户分群与销售结构可视化分析

陈俊源

（嘉兴大学 数据科学学院）

摘要

巴西是拉丁美洲规模最大的电子商务市场，平台型卖家在规模扩张中普遍面临留存薄弱的结构性难题。本文以 Kaggle 公开的 Olist 巴西电商数据集为对象，经官方命令行工具合规获取，依 CC BY-NC-SA 4.0 许可使用；以订单表为事实核心，通过主外键校验、一对多表预聚合与时间窗过滤，构建 97,308 条订单、94,136 位客户的主分析集，应用 RFM 八分类、同期群留存、帕累托/ABC、波士顿矩阵与 Holt 阻尼趋势预测五个模型，并以 Matplotlib 与 Streamlit 完成静态图表与多组件联动大屏。结果表明：窗口内复购率仅 3.03%，94.38% 的成交额来自一次性客户；次月留存由 100% 跌至 0.49%；17 个 A 类品类贡献 79.71% 的销售额；金牛品类占 52.72% 但增速跑输大盘；预测模型回测 MAPE 为 28.79%。研究认为 Olist 属拉新驱动型平台，留存失效而非流量不足构成主要瓶颈。

关键词

Olist 电商；RFM 客户分群；同期群留存；帕累托分析；可视化大屏

1 引言

1.1 研究背景

巴西是拉丁美洲规模最大的电子商务市场，分期付款与银行票据（boleto）支付的普及降低了线上消费门槛。Olist 连接中小卖家与主流电商平台，其公开交易记录覆盖 2016 年 9 月至 2018 年 10 月的订单，为观察新兴市场平台型电商提供了样本。此类平台卖家分散、客单价低，增长依赖持续拉新，留存薄弱容易被增长曲线掩盖。

1.2 研究目的

本文回答三个问题：客户价值在人群之间如何分布，销售结构是否过度集中于少数品类，现有增长趋势能否延续。研究不以成交总额为终点，而以客户分群与销售结构两条线索定位增长的真实痛点。

1.3 研究意义

实践上，结论可为拉美本地与跨境卖家的客户分层运营、品类投放与预算编制提供参考；方法上，本文呈现从合规获取、数据治理、模型选择到可视化呈现的闭环，对同类研究具复用价值。

2 数据准备与预处理

2.1 数据源介绍

数据集由 9 张关系表构成，合计 52 个字段、约 126 MB；来源为 Kaggle 的 Brazilian E-Commerce Public Dataset by Olist（https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce，文献[5]）。原始订单表 99,441 行，覆盖 2016-09 至 2018-10；客户表 99,441 行、去重后 96,096 位客户；订单项、支付、评价与邮编地理四表分别为 112,650 行、103,886 行、99,224 行与 1,000,163 行。

2.2 合规获取方式

数据经 Kaggle 官方命令行工具下载，命令为 kaggle datasets download -d olistbr/brazilian-ecommerce，获取日期 2026-10-26，全程未使用爬虫、未模拟登录、未做网页解析，属课程白名单的官方方式。金额单位依来源推定为巴西雷亚尔，全文以 R$ 记；未使用 Faker 或任何合成数据工具补足记录，未做抽样，样本规模完全由原始数据决定。

2.3 数据来源合规声明

数据集采用 CC BY-NC-SA 4.0 许可（署名—非商业性使用—相同方式共享 4.0 国际）。本项目为课程作业，属非商业使用；依相同方式共享条款，派生数据以相同协议发布，许可副本见仓库 data/clean/LICENSE，来源说明见 data/clean/SOURCE.md。数据源 URL 为

https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce，获取日期 2026-10-26，规模为 9 个 CSV、52 个字段、约 126 MB。真实性声明：未使用 Faker 或任何合成数据生成工具补足、替换记录，全部记录来自上述官方数据源。

2.4 数据集概述

九张表构成星型结构：订单表为事实核心，主键 order_id、外键 customer_id，记录下单至送达五个时间戳及订单状态；明细表以 order_id 与 order_item_id 为复合主键，逐项记录商品、卖家、单价与运费；支付表、评价表按 order_id 关联订单；客户表主键为 customer_id，另给跨订单稳定的 customer_unique_id；商品、卖家、品类对照与邮编地理四表提供维度属性。关联顺序与聚合粒度见 3.3。

3 数据清洗与治理

3.1 数据清洗

缺失与重复单独处理：评价表 99,224 行按 review_id 去重后 98,128 行（1,096 行重复），评价字段缺失率约 21%，保留缺失不填补；地理表 1,000,163 行按邮编取经纬度中位数压到 19,015 行，同一邮编最多 1,146 条、中位 29 条；客户表聚合为 96,096 行（减少 3,345 行）；订单表过滤后为 97,308 行（减少 2,133 行）。价格异常值以 IQR/P99 标记但不删除，避免误删真实大单。

3.2 数据转换

类型统一上，邮编前缀、订单号、客户与商品标识一律以字符串读入，避免前导零丢失；金额转浮点，五个时间戳转 datetime。日期派生年、季、月、年月与周几五个维度，按自然月聚合，保证月度序列与同期群口径一致。指标派生 payment_total、price、运费异常标记与 is_late 列，均在 02_clean.py 一次生成，下游只读不改；编码统一用带 BOM 的 UTF-8，避免中文表头乱码。

3.3 数据整合

治理聚焦三处结构性风险。一是客户标识桥接：订单表仅有订单级 customer_id，跨订单稳定的 customer_unique_id 只在客户表；原始两者为 99,441 与 96,096，差值 3,345 即重复购买订单，按 customer_id 汇总会抹平复购，故先关联取回再聚合。二是一对多表膨胀：支付一单多笔、明细一单多件、评价一单多评、地理一邮编多坐标，直接连接会放大成交额，故先聚合到订单级与邮编级再左连接。三是时间窗：剔除 2016 年与 2018-09 及以后记录，仅保留已送达与运输中订单，得 97,308 条，为原始订单的 97.86%。整合结果导出订单、明细、客户、订单级支付、订单级评价、邮编地理与全状态订单共 7 张表，统一用带 BOM 的

UTF-8 编码并附字段字典。

4 商业分析模型

4.1 模型选型

本文选取 5 个模型，均以同一份清洗结果为输入：RFM 以 customer_unique_id 为粒度，用最近购买间隔、购买频次与支付金额刻画客户价值（文献[1]）；同期群以首单年月分群、按月龄追踪留存（文献[2]）；帕累托与 ABC 按品类销售额降序累计，以 80%、95% 两个断点分级；波士顿矩阵按份额与增速划分四象限；Holt 阻尼趋势外推月度支付金额 3 个月（文献[3][4]）。

4.2 参数与阈值设定依据

RFM 方面，快照日取最大下单日次日即 2018-08-30；R、M 以中位数二分（219 天、R$107.78），R 越小、M 越大记高分。F 不能沿用中位数——复购率仅 3.03%，F 中位数恒为 1，二分会使全部客户落同一侧，故改用业务阈值：1 单低分、2 单及以上高分，构成 2×2×2 八分类。

同期群方面，限定 2017-01 至 2018-06，保证每群至少 2 个月观察期，月龄 0–12；第 n 月留存率为该群首购后第 n 月仍有购买的客户占比。

ABC 方面，累计占比 ≤80% 为 A 类、80%–95% 为 B 类、>95% 为 C 类，阈值取帕累托经验值而非本数据拟合。

波士顿矩阵方面，横轴切分线取品类份额中位数 0.3495%；纵轴切分线取大盘增速 140.63%，两期均取 1–8 月等长窗口以规避 2018 年截断造成的低估。

预测方面，样本不足两个完整季节周期，Holt-Winters 加法季节模型无法估计初始季节项（需 ≥24 个月），故与 Holt 线性、阻尼趋势并列比较，以前 17 个月训练、2018-06 至 08 验证择优；95% 预测区间按残差近似，残差标准差 14.51 万，sigma_h=sigma×sqrt(h)，df=10、t=2.228，区间随步长扩大。

4.3 模型计算与验证

RFM 结果显示，94,136 位客户中复购者 2,848 户占 3.03%，仅贡献 5.63% 成交额；“重要发展”与“重要挽留”以 47.33% 客户贡献 75.31% 成交额。近九成半收入由一次性客户支撑，属拉新驱动、留存失效结构（见图 12、图 13）。

同期群纳入 18 群、81,945 位客户，覆盖 87.05%，排除 2018 年 7–8 月首购、观察期不足的 12,191 位。曲线呈断崖加长尾：第 0 月 100%，次月 0.49%，第 3、6、9、12 月为 0.25%、0.26%、0.16%、0.21%。各群次月留存 0.22%–0.71%，说明流失几乎都发生在首

购后 30 天内，与获客批次无关。需说明 3.03% 指任一时点复购过的客户占比，0.49% 指恰在次月复购的月留存率，二者不可混用（见图 14、图 15）。

帕累托显示，72 个品类中 A 类 17 个（23.61%）贡献 79.71%，B 类 16 个 15.18%，C 类 39 个仅 5.11%；前 8 个品类合计 54.58%，第 8 个使累计跨过 50%（见图 18、图 19）。

波士顿矩阵的四象限为 18、18、17、17 个品类，另有 2 个基期为 0 的品类（diapers_and_hygiene、flowers）记为“未定”，合计 72 个；金牛贡献 52.72%。金牛“低增速”仅指跑输大盘，18 个中 17 个仍正增长，最高 136.5%，不可解读为衰退。剔除异常值后 garden_tools 跌出前十、toys 进入，秩相关 0.9138；异常记录占 7.39% 行数却承载 35.27% 金额，可能为批发/大件交易、需订单级核验，故双口径报告（见图 16、图 17）。

预测方面，线性趋势回测 MAPE 35.31%、RMSE 36.38 万；阻尼趋势为 28.79%、29.67 万，择优外推 2018-09 至 11，点预测 114.85、116.32、117.64 万。验证期实际值为 102.01、103.61、99.38 万，6–7 月回升、7–8 月转跌，并非逐月下行；模型仍外推上行，方向相反。可见 2018 下半年已现走弱迹象，对拐点识别不足，输出宜作预算区间（见图 20）。

5 Python 数据分析与可视化

5.1 数据探索性分析

主分析集为 97,308 单、94,136 位客户，覆盖 2017-01 至 2018-08 共 20 个月；订单项 112,650 行、邮编 19,015 个、品类 72 个。缺失集中在评价文本（约 21%）与送达日期（2.98%），品类名称缺失 1.85%，均按 3.1 的策略保留。月度成交额介于 13.05 万至 116.22 万雷亚尔，峰值在 2017-11（见图 1、图 4）；第一大品类 health_beauty 占 9.32%，前 8 个品类合计 54.58%，长尾明显（见图 7、图 18）。

5.2 可视化模板复现

参照《Excel 数据可视化——从图表到数据大屏》的 30 种模板，选取 11 种以 matplotlib 复现，并在图表类型、布局、配色、标签、图例位置与标题设计六方面对齐。复现图同时承担业务读图：柱形族（图 1、2、3、8、9）看规模与结构，折线族（图 4、5）看趋势，环形/玉玦（图 6、7）看单一构成，滑珠/哑铃（图 10、11）看横向对比。

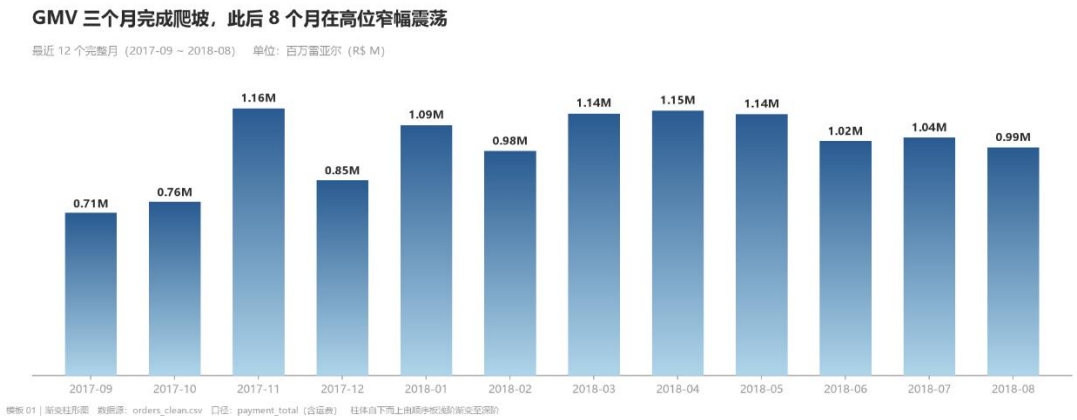


图 1　渐变柱形图：12 个月 GMV

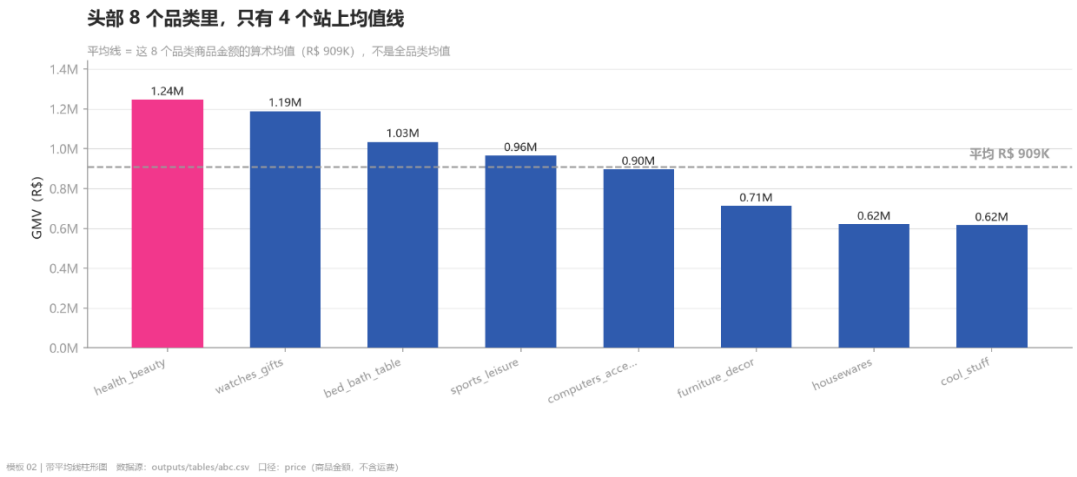


图 2　带平均线柱形图：Top 8 品类

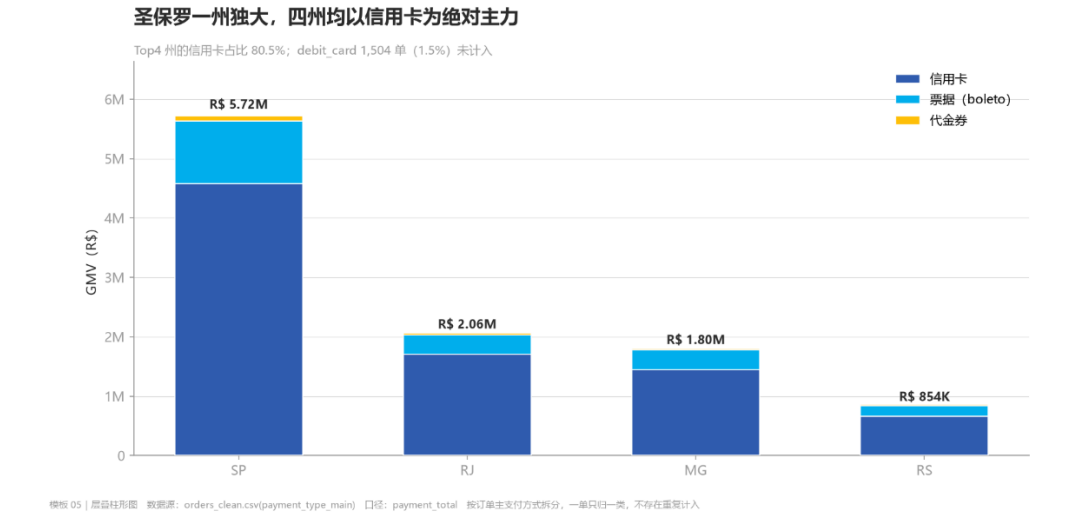


图 3　层叠柱形图：四州支付结构



图 4　平滑折线图：12 个月订单量

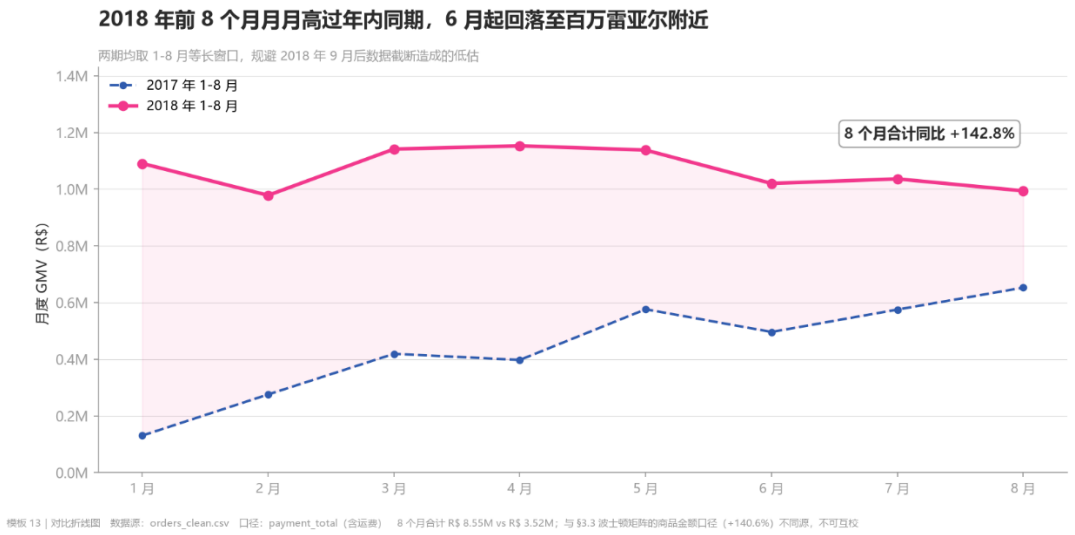


图 5　对比折线图：两期同期 GMV

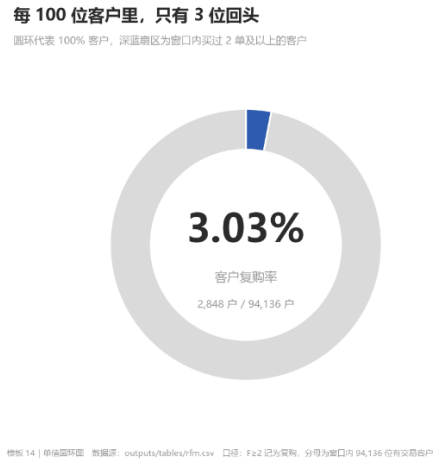


图 6　单值圆环图：客户复购率

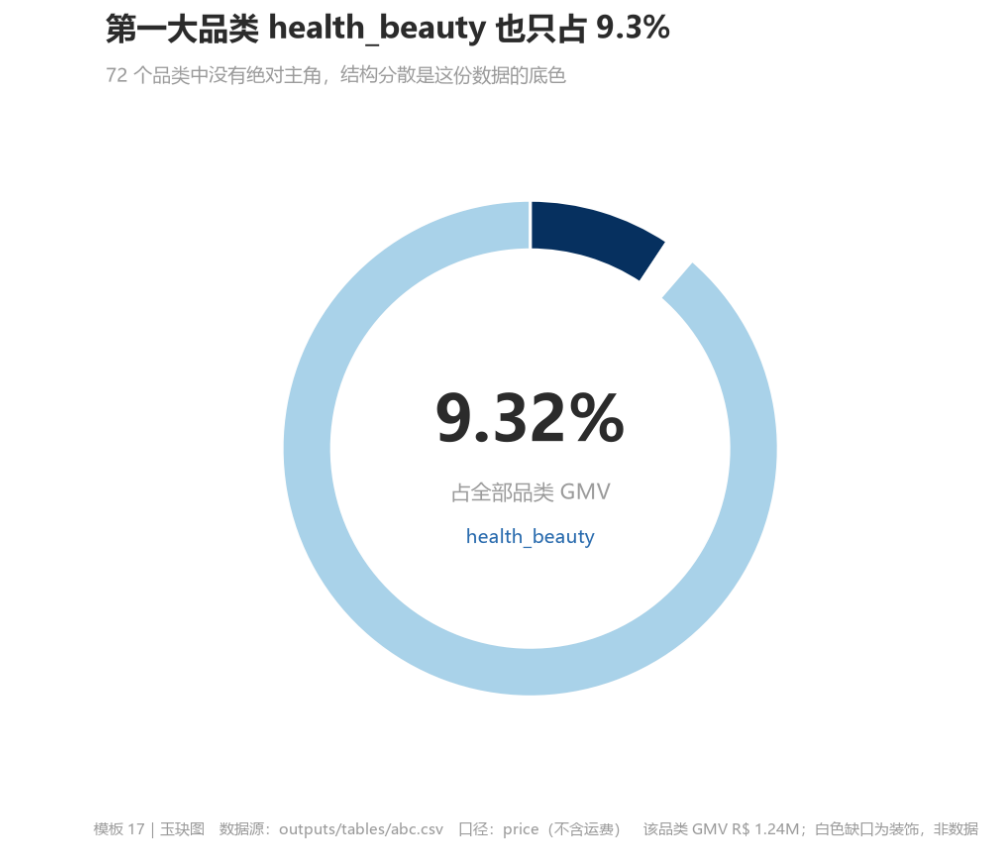


图 7　玉玦图：第一大品类占比

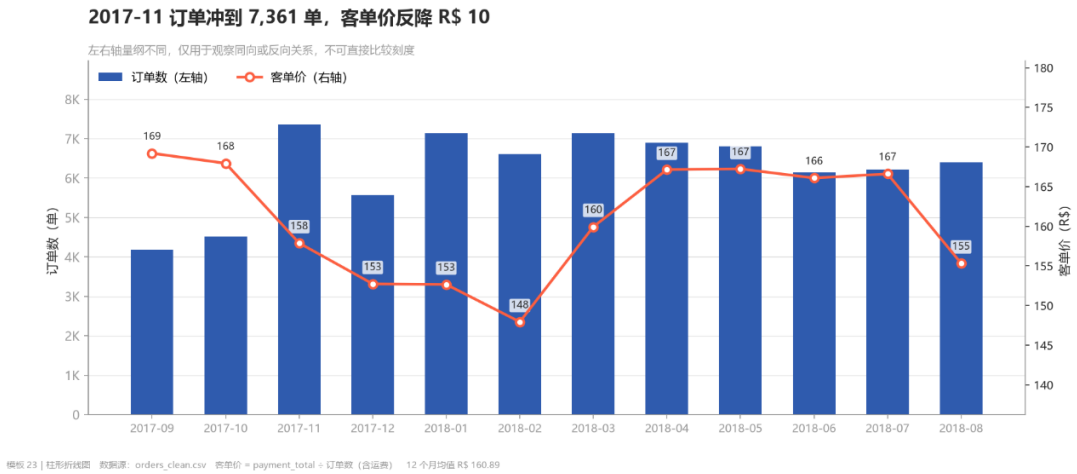


图 8　柱形折线图：订单量与客单价

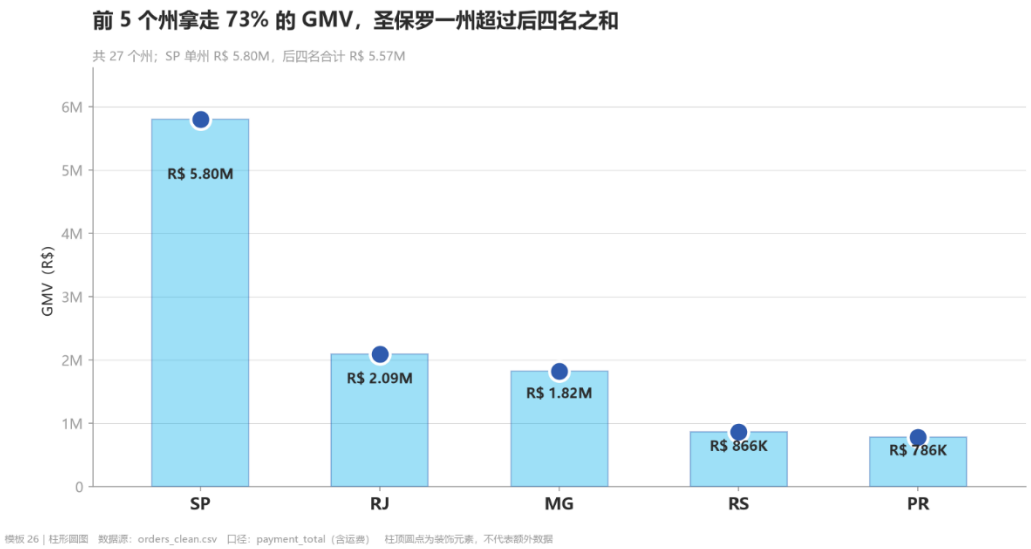


图 9 柱形圆图：Top 5 州 GMV



图 10 滑珠图：四州满意度

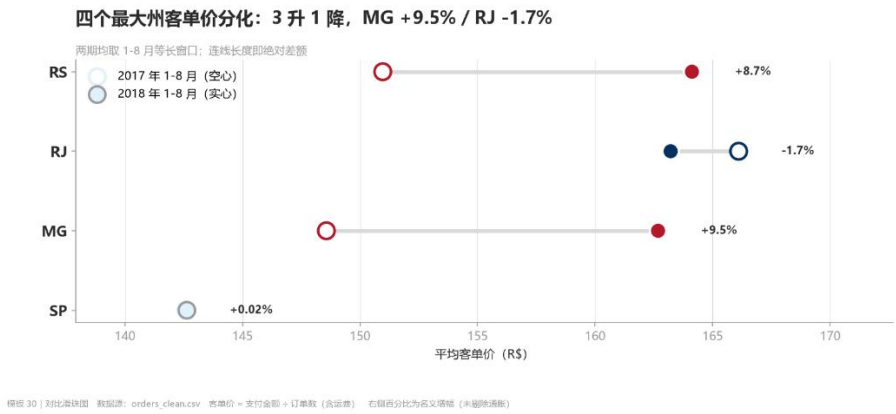


图 11 对比滑珠图：两期客单价

5.3 业务模型图

第 4 章五个模型对应 9 张业务模型图：RFM 见图 12、图 13，同期群见图 14、图 15，波士顿矩阵见图 16、图 17，帕累托与 ABC 见图 18、图 19，预测见图 20。本节按模型顺序集中列出，读图结论与 4.3 一致。

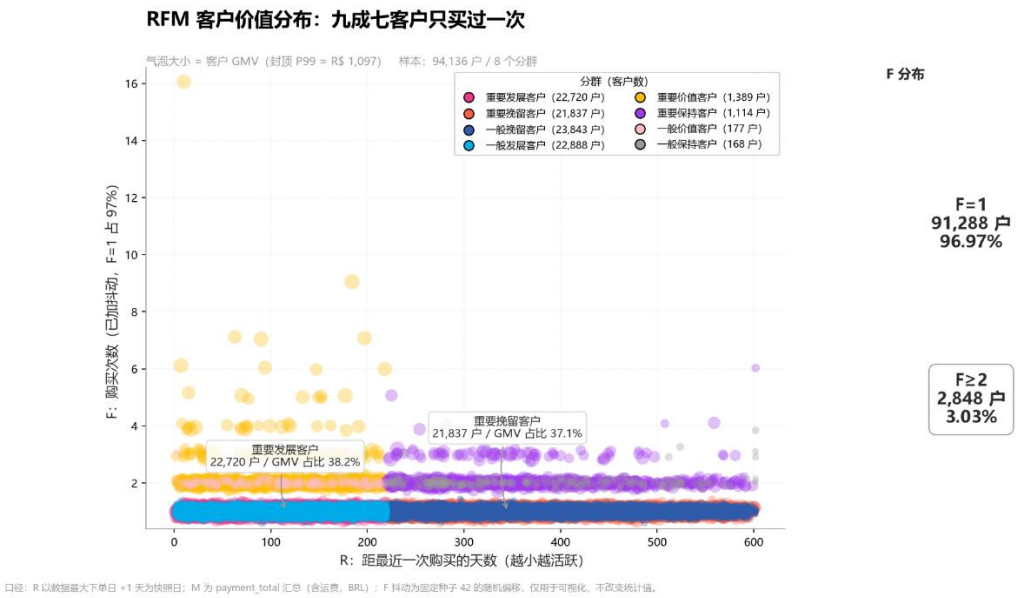


图 12　RFM 客户分群气泡散点图（右侧面板：F=1 占 96.97%，F≥2 占 3.03%）

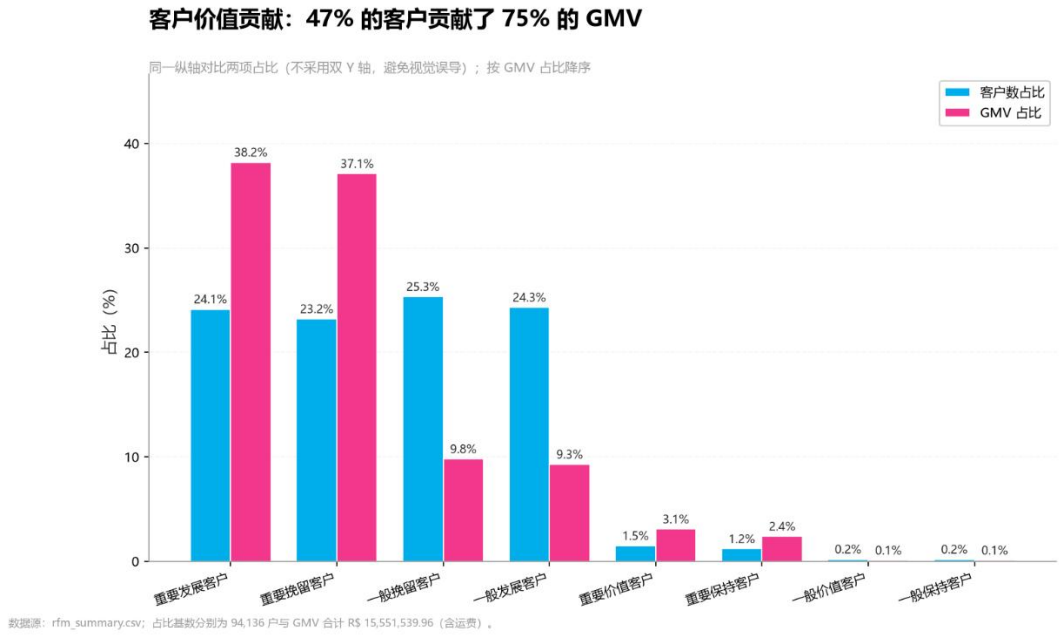


图 13　客户价值贡献：人数与 GMV 对比

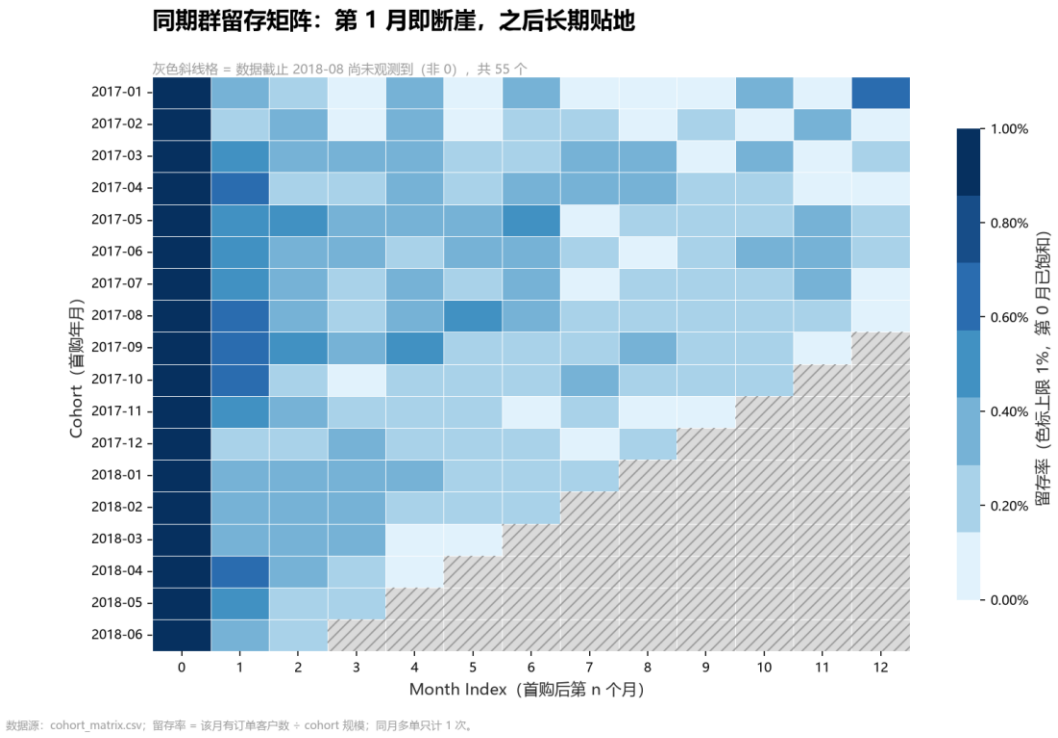


图 14　同期群留存热力图（灰色斜线=未观测，不按 0 计）

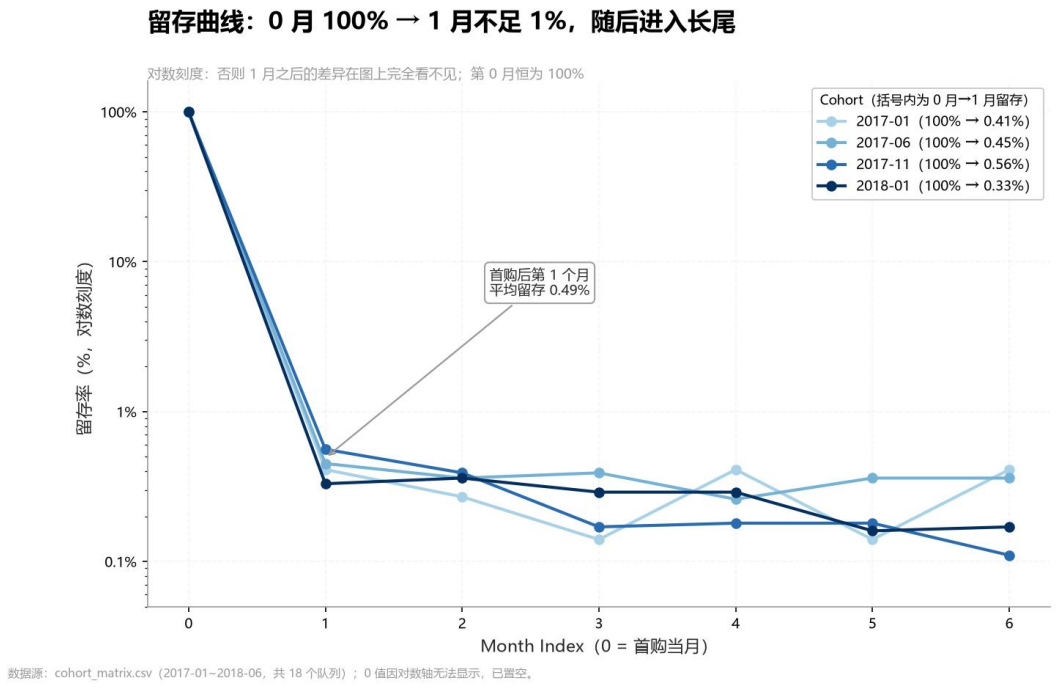


图 15　代表性同期群留存曲线

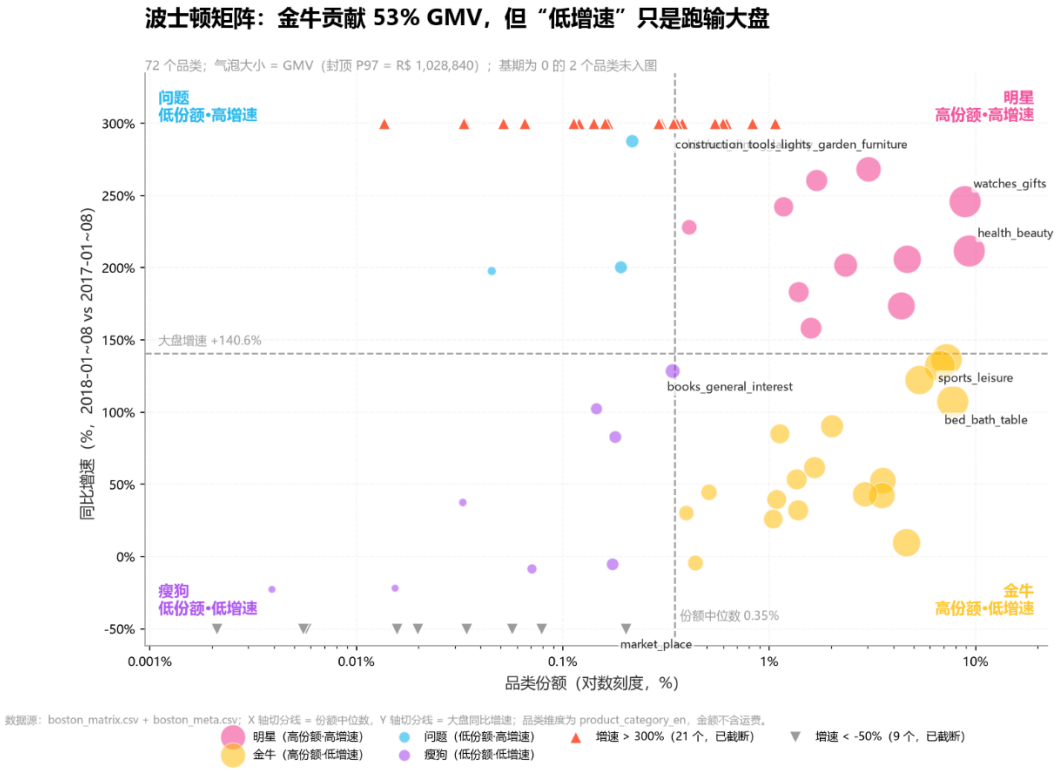


图 16　品类波士顿矩阵四象限图

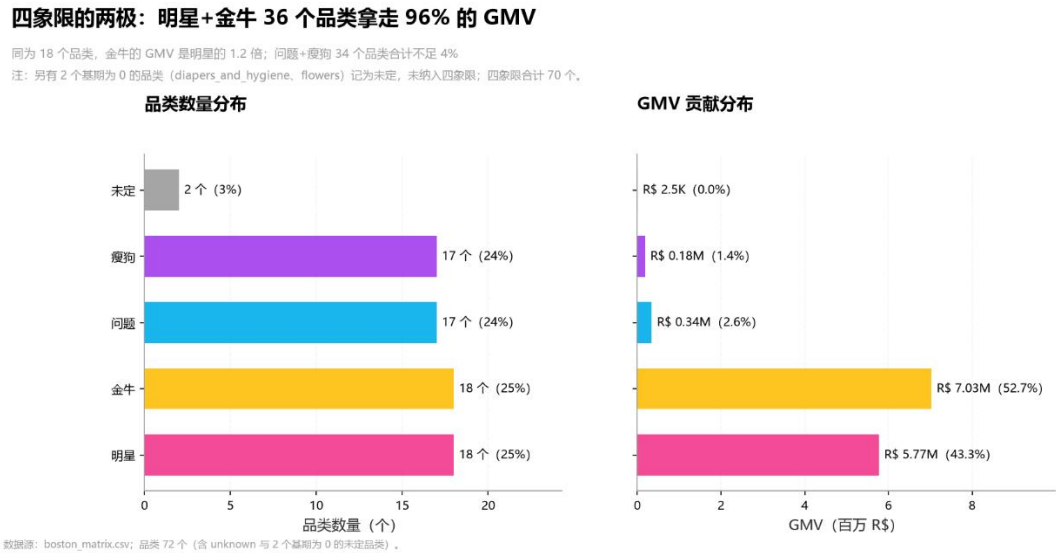


图 17　四象限的品类数与 GMV 分布（未定品类 2 个，未纳入四象限）

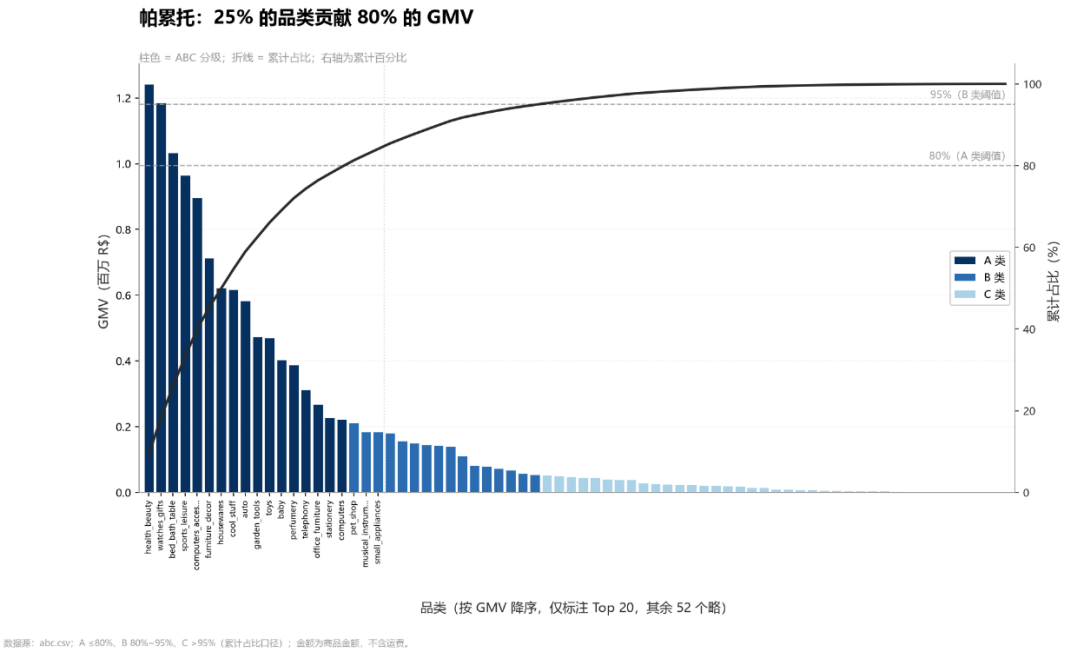


图 18　品类帕累托曲线

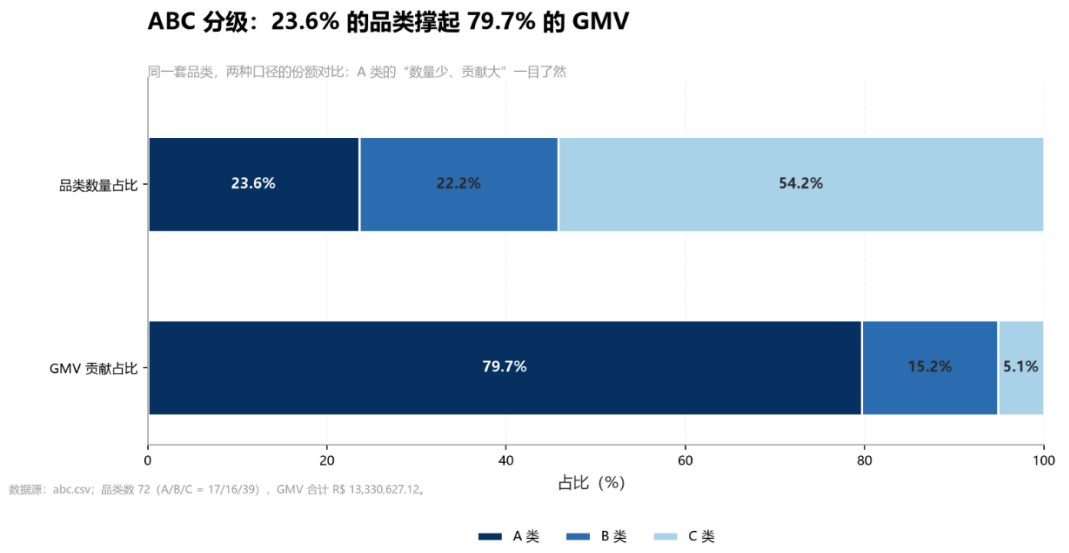


图 19　ABC 三级贡献对比

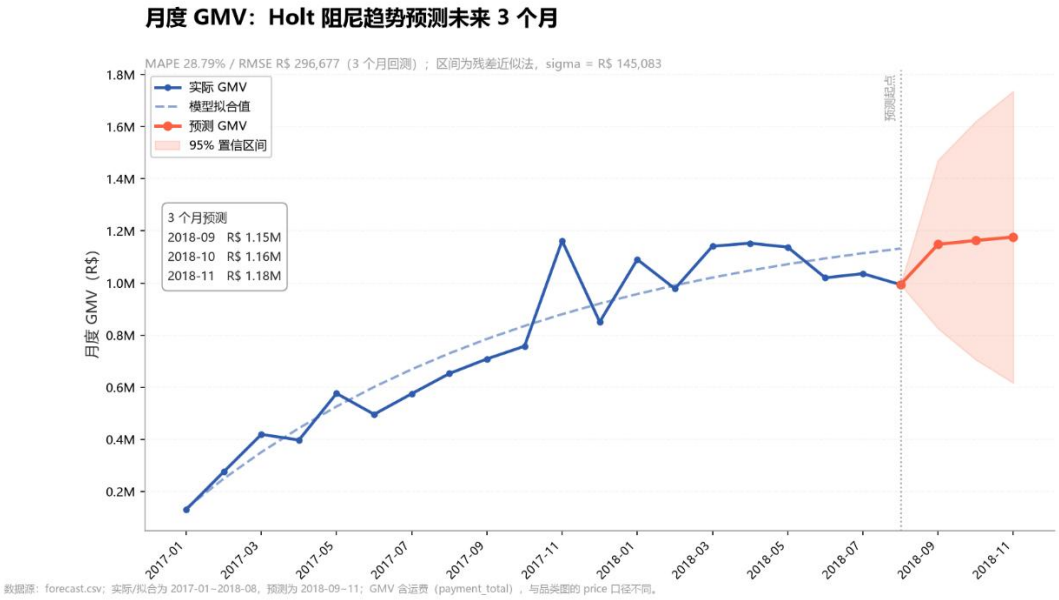


图 20　月度 GMV 预测与 95% 预测区间

5.4 交互式可视化大屏

大屏以 Streamlit 实现宽屏布局，含筛选器、KPI、趋势、品类环形、州地图、RFM 散点与明细表共 7 个组件。KPI、趋势、品类、地图与明细共用筛选后的订单项数据，RFM 仅按客户集合过滤、R/F/M 仍为全窗口口径；全量为 R$13,330,627.12、97,308 单、94,136 位客户，筛选变更即整页重算。地图以客户经纬度州内均值作质心，底图用本地 topojson；点击州写回筛选器形成单向钻取；大屏金额取商品金额，与支付金额分属两套口径。

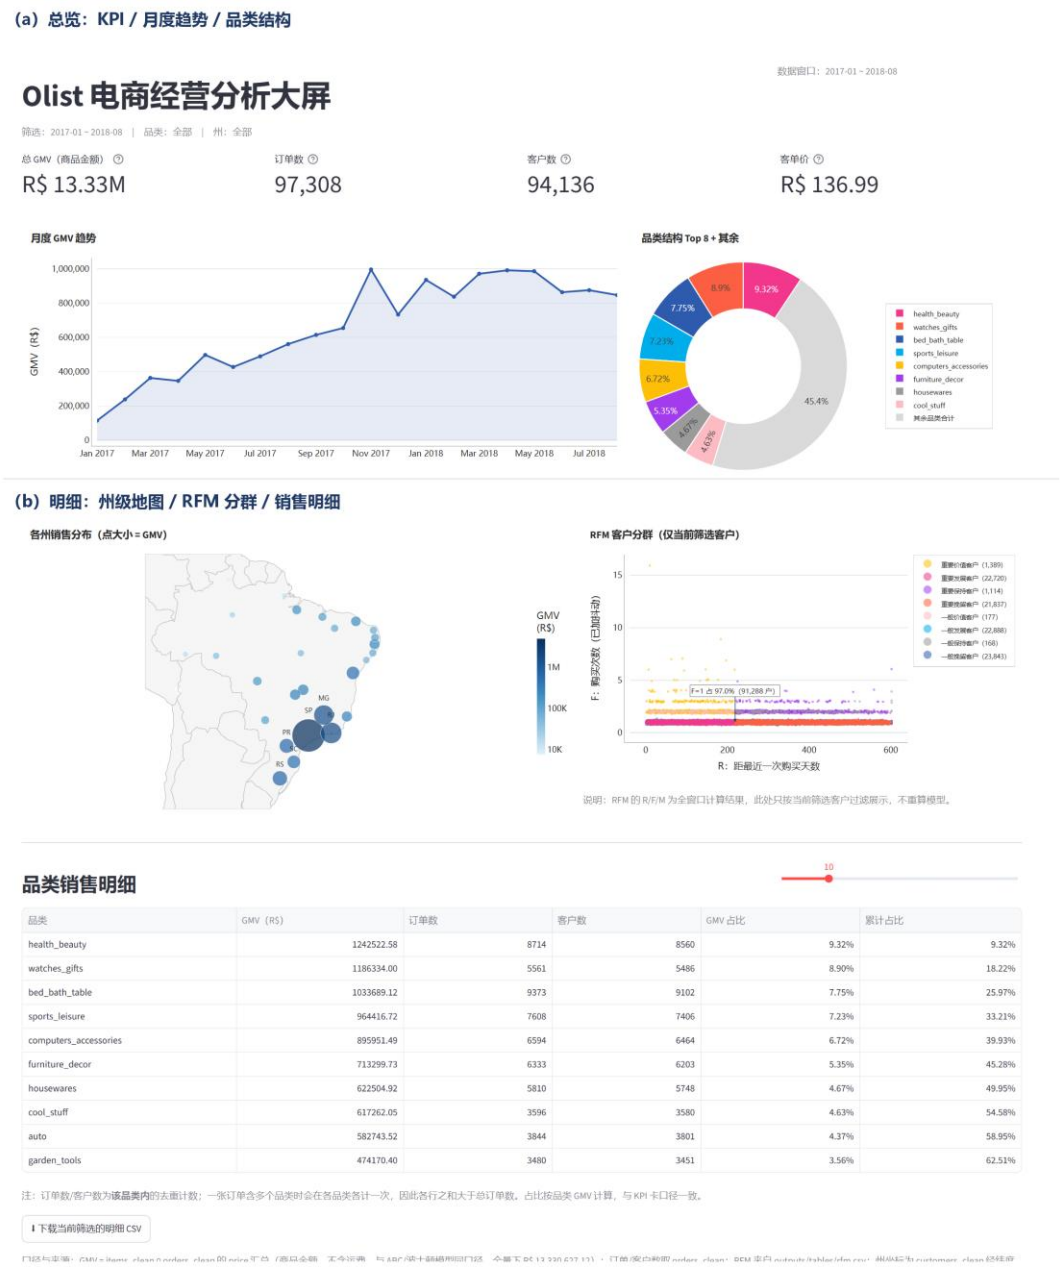


图 21　Olist 商业分析交互式大屏（a 总览 / b 明细）

Python 与 Excel 的差异不在效率，而在能力边界。RFM 图有 94,136 个点、96.97% 的 F=1，Excel 在此量级不适合做交互散点；Python 以固定种子加抖动、收小点径，既摊开重叠又可复现。Excel 图表是静态对象，无法让多图随一次点击重算；Streamlit 以响应式执行实现 Web 级钻取。配色、阈值与抖动参数固化在脚本，重跑即得同一张图。需说明：本项目未用 Excel 出图，仅用其核对结果，表 1 描述能力边界而非性能基准。

表 1　Python 与 Excel 能力边界对比

维度	Python/Streamlit	Excel	本项目证据
数据量	94,136 点、112,650 行可交互	十万行交互受限	图 12、图 21
交互	筛选、悬停、下钻	静态图表	7 组件联动
联动	一次筛选全页重算	手工改图	图 21
复现	脚本 + 固定随机种子	手工调色	README/代码

6 商业案例分析

6.1 案例背景

本文以 Olist 平台 2017-01 至 2018-08 的 97,308 笔已送达与运输中订单为案例对象，涉及 94,136 位客户、72 个品类。记录含时间戳与支付、评价信息，但不含营销活动与流量来源，故分析以客户行为与销售结构为主线，不对促销活动做归因。

6.2 结果解读

三个模型指向同一诊断：平台以拉新驱动规模、以一次性交易支撑收入。3.03% 复购率与 0.49% 次月留存表明客户首购后即流失，94.38% 成交额由一次性客户贡献；17 个 A 类品类占 79.71%，金牛只跑输大盘而非衰退；预测向上而实际 6–7 月回升、7–8 月转跌。

6.3 商业建议

建议一，建立首月复购召回：首购后第 7、21、30 天三档触达，定向“重要发展”与“重要挽留”。依据是次月留存仅 0.49%，两类以 47.33% 人数贡献 75.31% 成交额；若留存提至 1.0%，按 0.51pp×94,136≈480 户/月，每户月均 343 元、持续 12 个月约增 198 万，按一次性客户均值 138 元测算约 79 万，故表述为约 80–198 万情景区间，而非单点承诺。

建议二，向金牛品类倾斜库存与履约：上调 18 个金牛备货深度，并对 computers 这类剔除异常单价后由第 17 位跌至第 72 位的品类设大单依赖预警；依据是金牛占 52.72% 成交额且 17 个仍正增长。

建议三，以客单价对冲增速走弱：转向存量，对 23,843 户“一般挽留”客户做组合捆绑与满额免运；依据是模型外推上行而实际 6–8 月走弱，客单价每升 5% 可静态增约 R$66.7 万。

7 结论与展望

7.1 研究结论

其一，Olist 属拉新驱动、留存失效的平台，3.03% 复购率与 0.49% 次月留存界定了增

长性质：规模来自新客而非客户资产。其二，结构高度集中，17 个 A 类占 79.71%、18 个金牛占 52.72%，集中既是效率也是风险。其三，2018 下半年已现走弱迹象，但 20 个月样本不足以断言长期拐点，需后续验证。

7.2 局限性与展望

研究有三处局限：数据仅 20 个月，不足两个季节周期，只能退化为趋势外推；缺少营销活动与流量数据，无法把留存下降归因到具体动作；同期群以窗口内首单定义，早期群体规模略高估。后续可引入营销触点与流量数据，或滚动回测验证拐点。

7.3 AI 使用披露

环节	AI 参与方式	本人核验方式
数据清洗	生成 02_clean.py 的代码框架与字段映射	逐行审查；手工修复字段归属、传参错位、弃用 API 后复跑通过
模型实现	提供参数选择建议（中位数切分、F 维业务阈值、回测切分点）与代码骨架	全部指标在本地复跑，与运行日志逐项比对；关键断言由脚本内置校验
图表绘制	生成绘图代码、版式调整与配色方案	逐图检查标题所述事实是否与实测一致，修正 4 处错误表述
文本撰写	提供章节结构建议与语句润色	数据口径、全部数字与结论逐条回溯到原始输出；三条商业建议可手工复算
结论与建议	未参与	由本人依据模型结果提出并验证

AI 工具：DeepSeek Harness、WorkBuddy（代码、图表与文本辅助）。

关键提示词示例：①“请基于 Olist 多表关系，设计 customer_unique_id 桥接与一对多表预聚合的清洗方案，并说明如何避免金额放大。”②“请检查 RFM 八分类的阈值设定，解释为什么 F 维不能用中位数，并给出可复现的校验点。”

声明：AI 未参与任何数据生成、补足或替换；未替代任何结论判断。原始数据仅经 Kaggle 官方命令行工具下载，处理过程全程可复现。

参考文献

[1] CHEN D, SAIN S L, GUO K. Data mining for the online retail industry: a case study of RFM model-based customer segmentation using data mining[J]. Journal of Database Marketing & Customer Strategy Management, 2012, 19(3): 197-208.

[2] REICHHELD F F, SASSER W E. Zero defections: quality comes to services[J]. Harvard Business Review, 1990, 68(5): 105-111.

[3] HYNDMAN R J, ATHANASOPOULOS G. Forecasting: principles and practice[M]. 3rd ed. Melbourne: OTexts, 2021.

[4] 李航. 统计学习方法[M]. 2 版. 北京: 清华大学出版社, 2019.

[5] OLIST. Brazilian e-commerce public dataset by Olist[DB/OL]. (2018)[2026-10-29]. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

附录

A 核心代码片段

完整代码见仓库 scripts/ 目录。为篇幅计，下列片段省略日志打印与断言，保留全部计算逻辑。

A.1 支付表预聚合（scripts/02_clean.py）

```
def build_payments(orders: pd.DataFrame, payments: pd.DataFrame) -> pd.DataFrame:
    """
    支付表 → 订单级汇总。
    依据：profiling 实测 103,886 行 / 99,440 个订单，每单最多 29 条支付记录，
         直接 join 会把金额放大数倍。
    """
    type_cnt = (payments.groupby(["order_id", "payment_type"], observed=True)
                        .size().reset_index(name="cnt")
                        .sort_values(["order_id", "cnt", "payment_type"],
                                     ascending=[True, False, True]))
    main_type = (type_cnt.drop_duplicates("order_id")[["order_id", "payment_type"]]
                         .rename(columns={"payment_type": "payment_type_main"}))

    pay = payments.groupby("order_id", as_index=False).agg(
        payment_total=("payment_value", "sum"),
        payment_record_cnt=("payment_sequential", "count"),
        payment_type_cnt=("payment_type", "nunique"),
        payment_installments_mean=("payment_installments", "mean"),
    )
    pay = pay.merge(main_type, on="order_id", how="left")
    pay["payment_installments_mean"] = pay["payment_installments_mean"].round(2)

    add_p99_flag(pay, "payment_total", "is_payment_outlier")
    return pay
```

A.2 RFM 打分与八分类（scripts/03_rfm.py）

```
def score_and_segment(rfm: pd.DataFrame) -> tuple[pd.DataFrame, dict]:
    # 阈值：中位数（金额与时长右偏，中位数抗极值）
    r_median = rfm["R"].median()
    m_median = rfm["M"].median()

    # R 越小越好，故 <= 中位数 记 2 分
    rfm["R_score"] = (rfm["R"] <= r_median).map({True: 2, False: 1}).astype("int64")
    # M 越大越好，故 > 中位数 记 2 分
    rfm["M_score"] = (rfm["M"] > m_median).map({True: 2, False: 1}).astype("int64")
    # F 用业务断点，绝不能用中位数：复购率仅 3.03%，中位数恒为 1
    rfm["F_score"] = (rfm["F"] >= 2).map({True: 2, False: 1}).astype("int64")

    keys = [(int(r), int(f), int(m))
            for r, f, m in zip(rfm["R_score"], rfm["F_score"], rfm["M_score"])]
    rfm["Segment"] = [SEGMENT_MAP.get(k, "未分类") for k in keys]

    n_unmapped = int((rfm["Segment"] == "未分类").sum())
    if n_unmapped:
        raise ValueError(f"有 {n_unmapped} 户未能映射到 8 类，打分列取值异常")

    return rfm, {"r_median": float(r_median), "m_median": float(m_median)}
```

A.3 大屏州级散点地图（scripts/08_dashboard.py）

```
def render_map(o: pd.DataFrame, it: pd.DataFrame, customers: pd.DataFrame) -> go.Figure:
    # 订单级商品金额 → 按州汇总
    order_gmv = it.groupby("order_id", as_index=False)["price"].sum()
    od = o[["order_id", "customer_state"]].merge(order_gmv, on="order_id",
how="left").fillna({"price": 0})
    by_state = od.groupby("customer_state", as_index=False)["price"].sum()

    # 州质心（客户维表经纬度均值），避免额外引入 geojson
    cent = customers.groupby("customer_state", as_index=False)[["lat", "lng"]].mean()
    m = by_state.merge(cent, on="customer_state", how="inner")
    m = m[m["price"] > 0].sort_values("price", ascending=False)

    if m.empty:
        fig = go.Figure()
        fig.add_annotation(text="当前筛选下没有可展示的州", showarrow=False,
font=dict(size=14))
        return style_fig(fig, "各州销售分布")

    size = np.sqrt(m["price"] / m["price"].max()) * 42 + 6
```

```
    log_gmv = np.log10(m["price"].clip(lower=1))
    labels = [st_ if i < 6 else "" for i, st_ in enumerate(m["customer_state"])]

    fig = go.Figure(go.Scattergeo(
        lon=m["lng"], lat=m["lat"], text=labels, hovertext=m["customer_state"],
        customdata=m["price"].values,
        mode="markers+text", textposition="top center",
        textfont=dict(size=9.5, color=TXT),
        marker=dict(size=size, color=log_gmv, colorscale=MAP_SCALE,
                    cmin=float(log_gmv.min()), cmax=float(log_gmv.max()),
                    line=dict(width=0.6, color=BG),
                    colorbar=dict(title="GMV<br>(R$)", thickness=12, len=0.62,
                                  tickvals=[3, 4, 5, 6],
                                  ticktext=["1K", "10K", "100K", "1M"])),
        hovertemplate="%{hovertext}<br>GMV R$ %{customdata:,.0f}<extra></extra>",
    ))
    fig.update_geos(
        scope="south america", showcountries=True, countrycolor=rgba(AXIS, 0.55),
        showland=True, landcolor=rgba(GRID, 0.25), showocean=True, oceancolor=BG,
        showframe=False, projection_type="mercator",
        lataxis_range=[-35, 6], lonaxis_range=[-75, -32],
    )
    fig = style_fig(fig, "各州销售分布（点大小 = GMV）", height=CHART_HEIGHT + 40)
    fig.update_layout(margin=dict(l=0, r=0, t=48, b=0))
    return fig
```

调用处通过 config={"topojsonURL": "app/static/topojson/un/"} 指向本地底图，避免运行时依赖 cdn.plot.ly。

B GitHub 仓库链接与目录结构

仓库链接：https://github.com/Jy66466/First-Repository/tree/main/olist-ecommerce-analysis

说明：First-Repository 为个人项目合集；Olist 项目位于 olist-ecommerce-analysis/ 子目录，以下目录树以该子目录为根。

```
olist-ecommerce-analysis/
├── run_all.py                一键复现（7 步流水线，含预检）
├── requirements.txt          依赖清单（建议附 requirements.lock.txt）
├── README.md                 项目简介、数据来源、复现步骤、图表索引
├── LICENSE                   CC BY-NC-SA 4.0（派生数据）
├── data/
│   ├── raw/                  9 个原始 CSV（不入库，需 Kaggle CLI 下载）
│   ├── clean/                7 张清洗表 + LICENSE + SOURCE.md
│   └── schema.md             字段字典（7 张表逐字段说明）
```

```
├── scripts/
│   ├── 02_clean.py            清洗与治理
│   ├── 03_rfm.py              RFM 八分类
│   ├── 04_cohort.py           同期群留存
│   ├── 05_boston_abc.py       帕累托/ABC + 波士顿矩阵 + 敏感性
│   ├── 06_forecast.py         Holt 阻尼趋势预测（含三模型回测）
│   ├── 07_visuals.py          图 12–图 20（业务模型图）
│   ├── 08_dashboard.py        交互式大屏（图 21）
│   ├── 09_visuals_repro.py    图 1–图 11（模板复现图）
│   ├── static/topojson/un/south-america_110m.json   本地底图
│   └── .streamlit/config.toml 开启静态服务
├── outputs/
│   ├── figures/               fig01–fig21 *.png（150 dpi）
│   └── tables/                rfm / cohort / abc / boston / forecast 等
├── docs/                      大屏操作说明、图表索引、合规声明
└── logs/                      每次运行日志
```

复现步骤

```
pip install -r requirements.txt
kaggle datasets download -d olistbr/brazilian-ecommerce -p data/raw --unzip
python run_all.py
streamlit run scripts/08_dashboard.py
```

C 图表索引（图 1–图 21）

全部图形由 Python 脚本生成，150 dpi。论文图号按正文出现顺序排列：图 1–图 11 为模板复现图（物理文件 fig01–fig11），图 12–图 20 为业务模型图（物理文件 fig12–fig20），图 21 为大屏截图（物理文件 fig21）。图片目录：outputs/figures/。

C.1 图索引（图 1–图 21）

论文图号	物理文件名	图表名称	数据源与口径
图 1	fig01_gradient_bar.png	渐变柱形图：12 个月 GMV	orders_clean；payment_total
图 2	fig02_avg_line_bar.png	带平均线柱形图：Top 8 品类	abc.csv；price
图 3	fig03_stacked_bar.png	层叠柱形图：四州支付结构	orders_clean；payment_total
图 4	fig04_smooth_line.png	平滑折线图：12 个月订单量	orders_clean；订单数
图 5	fig05_compare_line.png	对比折线图：两期同期 GMV	orders_clean；payment_total
图 6	fig06_donut.png	单值圆环图：客户复购率	rfm.csv；F≥2
图 7	fig07_jade_ring.png	玉玦图：第一大品类占比	abc.csv；price
图 8	fig08_bar_line.png	柱形折线图：订单量与客单价	orders_clean；payment_total
图 9	fig09_bar_dot.png	柱形圆图：Top 5 州 GMV	orders_clean；payment_total
图 10	fig10_slider_dot.png	滑珠图：四州满意度	orders_clean；review_score
图 11	fig11_dumbbell.png	对比滑珠图：两期客单价	orders_clean；payment_total
图 12	fig12_rfm_bubble.png	RFM 客户分群气泡散点图（含 F 分布面板）	rfm.csv；R/F/M 客户级
图 13	fig13_rfm_gmv_bar.png	客户价值贡献：人数与 GMV 对比	rfm_summary.csv
图 14	fig14_cohort_heatmap.png	同期群留存热力图（斜线=未观测）	cohort_matrix.csv
图 15	fig15_cohort_line.png	代表性同期群留存曲线	cohort_matrix.csv
图 16	fig16_boston_bubble.png	品类波士顿矩阵四象限图	boston_matrix.csv；price
图 17	fig17_boston_bar.png	四象限的品类数与 GMV 分布（含未定 2 个）	boston_matrix.csv；price
图 18	fig18_pareto_line.png	品类帕累托曲线	abc.csv；price
图 19	fig19_abc_stacked.png	ABC 三级贡献对比	abc.csv；price
图 20	fig20_forecast_interval.png	月度 GMV 预测与 95% 预测区间	forecast.csv；payment_total
图 21	fig21_dashboard.png	Olist 商业分析交互式大屏（a 总览 / b 明细）	七组件联动，全局筛选

C.2 复现图读图提示

图号	模板号	一句话读图结论
图 1	01	12 个月 GMV 的渐变柱突出规模变化，2017-11 为峰值。
图 2	02	Top 8 品类中 health_beauty、watches_gifts 明显高于均值线。
图 3	05	SP 占四州支付结构约七成，RJ/MG/RS 依次递减。
图 4	11	订单量平滑折线保留峰谷，2017-11 为全年最高。
图 5	13	两期同期 GMV 对比显示 2018 年高于 2017 年，但增速后段放缓。
图 6	14	单值圆环把复购率 3.03% 作为唯一读数，强调留存薄弱。
图 7	17	玉玦图突出第一大品类 health_beauty 的 9.32% 占比。
图 8	23	柱形看订单量、折线看客单价，双轴呈现规模与价值。
图 9	26	Top 5 州 GMV 中 SP 约 509.6 万，远高于其余州。
图 10	29	四个最大州满意度集中在 76.4–84.7 分，极差仅 6.3 分，横向差异小。
图 11	30	四州客单价分化：MG +9.5%、RS +8.7%、SP +0.02%、RJ -1.7%。

C.3 附表（未在正文编号，随仓库提供 CSV）

编号	文件	内容
附表 1	outputs/tables/rfm_summary.csv	RFM 八分类的客户数、GMV、平均 R/F/M
附表 2	outputs/tables/abc.csv	72 个品类的 GMV、占比、累计占比、ABC 分级
附表 3	outputs/tables/boston_matrix.csv	品类的份额、增速、所属象限
附表 4	outputs/tables/metrics.csv	三组预测模型的 MAPE 与 RMSE

C.4 数据源署名

全部图表基于 Kaggle 公开数据集 Brazilian E-Commerce Public Dataset by Olist（olistbr/brazilian-ecommerce），许可协议 CC BY-NC-SA 4.0。派生数据（data/clean/）以相同协议共享，许可副本见 data/clean/LICENSE。